

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA



CURSO:
ANÁLISIS COMPUTACIONAL DE DATOS

Análisis del mercado laboral El perfil del Analista en Lima

Autor:
Wong Orrillo, Jose Francisco (202110394)

Profesor:
Espinoza Melgarejo, Jose Luis

Lima, 06 de Diciembre de 2025

Índice

1. Introducción	2
1.1. Contexto y Problemática	2
1.2. Objetivo del Proyecto	2
1.3. Hipótesis de Estudio	2
1.4. Contribución del Proyecto	3
2. Metodología: Data Life Cycle	3
3. Adquisición de Datos	3
4. Preprocesamiento de Datos	5
4.1. Data Cleaning: Nivel I	5
4.2. Data Cleaning: Nivel II	5
4.2.1. El caso de cargo	5
4.3. Data Cleaning: Nivel III	6
4.3.1. Tratamientos de valores faltantes	6
4.3.2. Tratamiento de outliers	7
4.4. Data Transformation	9
5. Análisis de Datos	9
5.1. Factores influyentes en el sueldo	9
5.2. Distribución de salario y modalidad por especializaciones top	10
5.3. Brecha salarial entre trabajos Full-Time y Part-Time	11
5.4. Distribución de tipo de contrato por modalidad	11
5.5. Transparencia salarial según Seniority	12
6. Conclusiones	13
6.1. Estructura del Mercado	13
6.2. Recomendaciones para el Postulante	13
6.3. Conclusiones Técnicas del Proyecto	13
A. Diccionario de Datos Inicial	14
B. Diccionario de Datos Final	15

1. Introducción

1.1. Contexto y Problemática

En la última década, el mercado laboral ha experimentado una migración masiva hacia ecosistemas digitales, convirtiendo a las bolsas de trabajo online (*job boards*) en los principales intermediarios entre la oferta y la demanda de talento. En el contexto de Lima Metropolitana, la demanda por perfiles analíticos ('Analista') ha crecido transversalmente en múltiples sectores industriales, impulsada por la transformación digital. Sin embargo, a pesar de la abundancia de ofertas publicadas, la toma de decisiones de carrera por parte de los profesionales de Ciencias de la Computación e Ingeniería suele carecer de una base empírica sólida, dependiendo frecuentemente de la intuición o de información anecdótica.

Esta carencia de transparencia genera ineficiencias en el mercado, las cuales se manifiestan principalmente a través de dos problemáticas identificadas:

- **Asimetría de Información:** en el mercado laboral peruano, existe una caja negra respecto a los salarios reales y las habilidades técnicas más demandadas.
- **Datos No Estructurados:** la información valiosa (salarios, tecnologías, requisitos) vive atrapada en texto libre dentro de portales de empleo, sin estandarización.

1.2. Objetivo del Proyecto

El objetivo de este proyecto es construir un pipeline de datos para estructurar esta información y revelar patrones ocultos sobre la valoración del perfil de Analista en Lima.

1.3. Hipótesis de Estudio

Para este proyecto, se han propuesto tres hipótesis que actuarán como puntos de kick-off para el análisis general que se realizará sobre el mercado laboral limeño:

1. **Hipótesis de Valorización (H1):** El mercado prioriza la especialización técnica (herramientas) sobre la educación formal (grados) para definir el salario.
2. **Hipótesis de Precariedad Digital (H2):** Las modalidades modernas (Remoto) conllevan una menor estabilidad laboral (contratos temporales) comparadas con la presencialidad.
3. **Hipótesis de Transparencia (H3):** La opacidad salarial es una táctica utilizada predominantemente en los niveles jerárquicos altos.

1.4. Contribución del Proyecto

La contribución principal del proyecto es explicar, mediante evidencia estadística, el salario ofertado dentro de las ofertas de trabajo a los analistas en Lima. Esencialmente, con este estudio se busca pasar de la anécdota ('Dicen que en ese trabajo pagan bien') a factores concretos ('El salario medio es X por factores W, Y, Z').

Los usuarios potenciales / principales beneficiado de este proyecto son los siguientes:

- **Estudiantes/Candidatos:** Para orientar su aprendizaje hacia las tecnologías más rentables.
- **Reclutadores:** Para realizar benchmarking salarial competitivo.
- **Instituciones Educativas:** Para alinear mallas curriculares con la demanda real.

2. Metodología: Data Life Cycle

El ciclo de vida de los datos diseñado para el proyecto no se salió del esquema tradicional a 3 fases:

1. **Ingesta de Datos:** Se optó por usar la técnica del Web Scraping para obtener el dataset inicial.
2. **Limpieza de Datos:** Se emplearon los 3 niveles de Data Cleaning para realizar la limpieza del dataset resultante del web scraping.
3. **Transformación de Datos:** Se aplicó Feature Engineer para obtener variables adicionales y útiles para la fase de análisis.

Para cada una de estas fases, se iba almacenando el dataset dentro de archivos CSV constantemente actualizados.




Figura 1: Diagrama del ciclo de vida de datos del proyecto,

3. Adquisición de Datos

Para la adquisición de datos, se utilizó como fuente al portal online de empleo Computrabajo Perú, seleccionando como parámetros de búsqueda al cargo de 'Analista' y a la ubicación a 'Lima'.

Se inició esta fase del proyecto examinando empíricamente las ofertas de trabajo dentro del portal, en busca de componer un formato para los registros que se almacenarían dentro del futuro dataset. Esta examinación reveló un gran desafío para determinar la estructura de los datos: la alta varianza de información presente dentro de las ofertas de trabajo.

Para entender la dificultad que presentaba esta varianza de información, es necesario discutir la estructura de las ofertas de trabajo presentada dentro del portal. Fundamentalmente, una oferta publicada en Computrabajo consiste de 3 bloques:

1. **Header:** que contiene el título de la oferta (por lo general es el cargo ofrecido por la empresa), el nombre de la empresa, la ubicación del lugar de trabajo, y las características principales de la oferta, las cuales son:
 - Salario mensual propuesto
 - Tipo de contrato
 - Jornada de trabajo (Parcial o a Tiempo Completo)
 - Modalidad de trabajo (Presencial, Remoto o Híbrido)
2. **Body:** que contiene un cuerpo de texto correspondiente a la descripción de la oferta colocada por la empresa.
3. **Requerimientos:** que contiene los requisitos mínimos exigidos a los postulantes.

El problema de la alta varianza de información surge debido a la falta de estructura dentro de los bloques de Body y Requerimientos, como también la inconsistencia de la aparición de ciertas características principales. Por ejemplo:

- Varias de las ofertas de la plataforma optaban por no publicar un salario, dejando ese campo rellenado con 'A discutir' o simplemente no lo incluían.
- Del total de requisitos posibles dentro del bloque de requerimientos, muy pocos tenían constantes apariciones a través de todas las ofertas. Esto nos impedía poder agregar todos los requisitos dentro de las variables a extraer, puesto que resultaría en un dataset con muy baja integridad y alta presencia de valores faltantes.
- Por último, el bloque de Body carecía totalmente de estructura o estandarización alguna, por lo que era casi imposible extraer información consistente de este bloque para todas las ofertas.

El compromiso realizado para afrontar este desafío fue seleccionar 11 atributos con apariciones lo suficientemente comunes dentro de cada oferta de trabajo recolectada. Con dicha selección, se diseñó un script de Python que realizó la extracción de datos con la técnica de Web Scraping, apoyándose de la librería BeautifulSoup para parsear los atributos contenidos en el HTML de las ofertas de trabajo.

El resultado de la extracción de datos fue un dataset de 4000 registros, compuesto por 11 atributos (columnas). El diccionario de atributos de dicho dataset se encuentra en la sección A dentro de los anexos del reporte.

4. Preprocesamiento de Datos

4.1. Data Cleaning: Nivel I

En el primer nivel de la limpieza, se realizaron las siguientes modificaciones al dataset:

- **Creación de identificadores únicos para los registros:** Para garantizar integridad, se creó una nueva columna `id_oferta` que contiene los identificadores para cada una de las ofertas, usando el Hash del Link contenido en `url_detalle`.
- **Simplificación de nombre de atributos:** se cambiaron los nombres de algunas columnas a otros más entendibles:
 - `cargo_especifico` → `cargo`
 - `ubicacion_provincia` → `ciudad`
 - `empresa_nombre` → `empresa`
- **Estandarización de tipos:** se cambió el tipo de la columna `experiencia_requerida` de `float64` a `Int64`, para que pueda manejar enteros con valores faltantes.

4.2. Data Cleaning: Nivel II

El segundo nivel de la limpieza se enfocó en limpiar 3 variables. Empezando por las dos más simples:

- **empresa:** el parser, en ocasiones, extrajo la calificación de la empresa dentro de la plataforma que aparece junto al nombre. Cabe aclarar que no todas las empresas contaban con dicha clasificación, por lo que tampoco se podría utilizar un análisis significativo con la calificación. Por ende, se borraron todas las apariciones de calificaciones dentro de los nombres de las empresa.
- **ciudad:** puesto que se había fijado la ubicación a Lima, el formato de dicha columna quedó en `'[ciudad], Lima'`. Por ende, solo se conservó el nombre de la ciudad en la columna.

4.2.1. El caso de cargo

Este atributo recibe su propia subsección puesto que requirió de una operación más compleja para limpiar.

Durante el proceso de adquisición de datos, se asumió que el título de la oferta de trabajo únicamente contenía el cargo ofrecido. Esto es verdadero para varios de las ofertas observadas durante la examinación inicial del portal, por lo que se fijó este detalle dentro de la lógica del parser.

Sin embargo, durante la revisión del dataset obtenido del web scraping, se reveló que fijar dicha lógica fue un craso error, puesto que no existía un claro estándar para los títulos de las ofertas dentro de Computrabajo Perú.

- Varias de las ofertas incluían en sus títulos información redundante a través del abuso de separadores ('/', '-', '|', etc).
- Había presencia de muchas variantes para el mismo cargo ('asesor', 'ASESORA', 'Asesor/a').
- Y lo más grave fue la aparición de frases para 'marketear' las ofertas ('GRAN OPORTUNIDAD!!!!').

El impacto de esta falta de estandarización para los títulos de las ofertas de trabajo fue la presencia de ~ 3000 cargos únicos dentro del dataset, lo que imposibilita realizar análisis significativos con esta columna.

La solución y método de limpieza, entonces, fue la implementación de un algoritmo de Extracción basada en Reglas (Rule-based Tagging), que se encargó de reducir la cardinalidad de `cargo` a 75 categorías estandarizadas. La figura 2 contiene el pie chart que visualiza las proporciones de los nuevos cargos dentro del dataset.




Figura 2: Distribución de cargos dentro del dataset

4.3. Data Cleaning: Nivel III

El último nivel de data cleaning consistió únicamente de dos partes: tratamiento de valores faltantes y tratamientos de outliers.

4.3.1. Tratamientos de valores faltantes

Examinando `df.info()` del dataset, se observó que solo tres columnas poseían valores faltantes:

- `experiencia_requerida`
 - **Integridad:** 44.9% (1796 valores válidos de 4000).

- **Acción:** Imputación por lógica de negocio. $NA \rightarrow 0$.
 - **Justificación:** Si la oferta no presentaba el requerimiento de experiencia mínima, entonces exige 0 años de experiencia previa.
- **jornada**
- **Integridad:** 99.38 % (3975 valores válidos de 4000).
 - **Acción:** Imputación por lógica del portal. $NA \rightarrow \text{'Completa'}$.
 - **Justificación:** Las ofertas de trabajo observadas en la examinación inicial revelaban que cada vez que no aparecía la jornada dentro de las características principales, la mención de trabajo a tiempo completo aparecía o en el título de la oferta o dentro del bloque Body.
- **salario_mensual_base**
- **Integridad:** 36.83 % (1473 valores válidos de 4000).
 - **Acción:** No imputación.
 - **Justificación:** Como se mencionó en la sección de adquisición de datos, a menudo las ofertas optaban por colocar como salario 'A discutir'. Los valores nulos dentro de esta columna son, por ende, MNAR, puesto que hay una justificación detrás de sus apariciones. En lugar de eliminar registros, se optó por crear una nueva columna **salario_publicado** que indica si la oferta de trabajo contiene el salario o no.

4.3.2. Tratamiento de outliers

Para el tratamiento de outliers, se examinaron las columnas **salario_mensual_base** y **experiencia_requerida**,

Para la observación de outliers dentro de la primera columna, se hizo la visualización del boxplot de distribución de salarios de las ofertas con **salario_publicado = 1**.




Figura 3: Distribución de salarios de las ofertas de trabajo

Del boxplot, se puede notar rápidamente que existen 3 valores atípicos con salarios superiores a 5000 soles. Examinando dichas ofertas, solo la que tiene `salario_mensual_base = 29500` parece un outlier real, puesto que a comparación de los otros dos sus requisitos son muy bajos para ofrecer esa cantidad de dinero. El resultado fue la eliminación de ese único outlier, dando un bloxplot más ajustado:




Figura 4: Distribución de salarios de las ofertas de trabajo sin outliers.

EL mismo procedimiento se aplicó para la columna `experiencia_requerida`, donde sólo se encontró un outlier con `experiencia_requerida = 10`. Sin embargo, el resto de atributos de dicha oferta revela los requerimientos son de los más altos del dataset, por lo que se puede explicar como una oferta de trabajo para un puesto de Lead/Expert. En consecuencia, se decidió no eliminar dicha oferta, puesto que presentaba información valiosa dentro de la columna, e incluso inspiró a la creación de la columna `nivel_experiencia` para categorizar los rangos de años de experiencia requerida.




Figura 5: Distribución de años de experiencia requerida por las ofertas de trabajo.

4.4. Data Transformation

La última fase del preprocesamiento del dataset consistió en la creación de columnas adicionales, que ayudarán con la realización del análisis.

- `nivel_experiencia`: creada a partir de *binning* de `experiencia_requerida`.
- `educacion_minima_valor`: creada a partir de *ordinal encoding* de `educacion_minima`.
- `es_remoto`, `es_presencial`: creadas a partir de *binary encoding* de `modalidad`.
- `segmento_salarial`: creada a partir de *segmentation* de `salario_mensual_base`.
- `tiempo_parcial`: creada a partir de *binary encoding* de `jornada`.

El diccionario del dataset resultante del preprocesamiento se encuentra en la sección B de los anexos del reporte.

5. Análisis de Datos

5.1. Factores influyentes en el sueldo

El primer análisis realizado fue la inspección de factores determinantes del salario, a través de plotear un mapa de calor con las variables `salario_mensual_base`, `experiencia_requerida`, `educacion_minima_valor`, `menciones_tecnologia` y `es_remoto`.




Figura 6: Heatmap de factores influyentes en el sueldo

Del mapa se puede observar que las únicas correlaciones positivas notables con el salario la poseen `experiencia_requerida` (0.54) y `educacion_minima_valor` (0.58). Al contrario de lo supuesto por la hipótesis H1, `menciones_tecnologia` tiene una correlación lo suficientemente débil (0.24) como para ser considerada un factor determinante para el salario de las ofertas de trabajo.

INSIGHT: Educación y experiencia sobre todo. El mercado sigue siendo conservador/tradicional. Paga por títulos y años en la silla, no por stacks tecnológicos de moda.

INSIGHT: Mito del todista. Acumular herramientas en el CV no garantiza mayor sueldo. El mercado penaliza al generalista superficial y premia la especialización.

5.2. Distribución de salario y modalidad por especializaciones top

El segundo análisis realizado fue la visualización del impacto del trabajo remoto en la distribución de salarios en el top 5 de especializaciones existentes. Para ello, se plotó un violin plot con las variables `cargo`, `salario_mensual_base` y `es_remoto`.




Figura 7: Violin plot de distribución de salario y modalidad por especialización

Del gráfico podemos notar una tendencia similar para los 5 cargos seleccionados: el volumen de la modalidad presencial tiende a ser igual o mayor a la de modalidad remota, pero las 'panzas' de las distribuciones del trabajo remoto tienden a llegar a valores más altos de salario.

INSIGHT: La 'prima' remota. Poco a poco, el trabajo remoto comienza a subir los techos salariales de la modalidad presencial.

5.3. Brecha salarial entre trabajos Full-Time y Part-Time

El tercer análisis realizado fue la comparación entre el salario promedio de los trabajos según el tipo de jornada. En específico, qué tan alejado estaba el salario de trabajos a tiempo parcial del salario de trabajos a tiempo completo. Para ello, se plotó un bar plot con las variables `salario_mensual_base` y `jornada`.




Figura 8: Salario promedio por modalidad de trabajo

Del gráfico se puede ver que el salario a tiempo parcial no está tan alejado del de tiempo completo, e incluso supera el benchmark impuesto (la mitad del salario promedio a tiempo completo).

INSIGH: Eficiencia oculta. Trabajar medio tiempo es 13 % más rentable por hora que trabajar completo.

5.4. Distribución de tipo de contrato por modalidad

El cuarto análisis realizado fue la comparación de distribución de contratos entre trabajos de modalidad presencial versus los de modalidad remota. Para ello, se plotó un bar plot horizontal con las variables `tipo_contrato` y `es_remoto`.




Figura 9: Distribución de contratos por modalidad

Del gráfico se puede ver que el 15 % de contratos de las ofertas de trabajo remoto son estables, a comparación del 11 % de contratos de las ofertas de trabajo presencial. Incluso en el caso inverso, hay más contratos temporales dentro de los trabajos presenciales (78 %) que dentro de los trabajos remotos (68 %).

INSIGHT: Estabilidad Contractual. Se derriba la hipótesis H2, el trabajo remoto no es más precario que el trabajo presencial.

5.5. Transparencia salarial según Seniority

El último análisis realizado fue la medición de transparencia salarial según el nivel de experiencia (Seniority) de las ofertas de trabajo. Para ello, se planteó un bar plot con las variables `nivel_experiencia` y `salario_publicado`.




Figura 10: Transparencia salarial según Seniority,

Del gráfico se puede ver que la mayoría de ofertas de trabajo dentro del dataset optaron por no publicar salarios. De las ofertas que sí publicaron salario, vemos que

la de mayor proporción son las de ofertas para cargos Junior, siendo mayor a las ofertas para cargos Mid-Level, Senior y Lead (en ese orden). Se observa la formación de una escalera, que va subiendo en proporción de salarios ocultos a medida que aumentábamos el nivel de experiencia.

INSIGHT: Opacidad ejecutiva. La transparencia es inversamente proporcional a la experiencia. Los sueldos altos no se publican, se negocian.

6. Conclusiones

6.1. Estructura del Mercado

El mercado laboral de Lima presenta una naturaleza dual.

- Por un lado, mantiene una **valoración profundamente tradicionalista**, donde la educación formal y la experiencia pesan el doble que las habilidades tecnológicas específicas.
- Por otro lado, el mercado comienza a mostrar una **modernización acelerada en las modalidades de trabajo**, donde el trabajo remoto no solo iguala la estabilidad del presencial, sino que ofrece techos salariales superiores, actuando como un mecanismo de arbitraje salarial.

6.2. Recomendaciones para el Postulante

Los datos sugieren un cambio de estrategia para los estudiantes y profesionales de Computer Science y Data Science:

- **Estrategia de Especialización:** La acumulación horizontal de herramientas ("Todista") tiene rendimientos decrecientes. La estrategia óptima es la especialización vertical académica y técnica.
- **Estrategia de Búsqueda:** Se identifica al trabajo remoto como la vía más efectiva para romper la barrera salarial local sin sacrificar estabilidad contractual.
- **Nicho de Eficiencia:** Se recomienda reconsiderar el trabajo a tiempo parcial (Part-Time), el cual demostró tener un retorno por hora invertida 13% superior al trabajo a tiempo completo, revelándose no como un subempleo, sino como un modelo de alta eficiencia.

6.3. Conclusiones Técnicas del Proyecto

Desde la perspectiva de Ingeniería de Datos, se concluye lo siguiente:

- La limpieza **basada en reglas semánticas** (diccionarios) demostró ser superior a las expresiones regulares puras para estructurar datos humanos altamente variables (cargos).

- La decisión de **no imputar salarios** (preservando los NaN) fue crítica para descubrir la “opacidad Ejecutiva”, revelando que la falta de datos en niveles senior no es un error, sino una característica del comportamiento del mercado (información asimétrica).

A. Diccionario de Datos Inicial

Atributo	Descripción	Tipo
url_detalle	Enlace único directo a la página de la oferta de trabajo	string
cargo_especifico	Título exacto del puesto de trabajo según la publicación de la empresa	string
empresa_nombre	Nombre de la empresa que postula la oferta	string
ubicacion_provincia	Ubicación geográfica específica (distrito o provincia) de la oferta	string
salario_mensual_base	Remuneración base expresada en Soles (S/.) de forma mensua	float64
experiencia_requerida	Años mínimos de experiencia laboral solicitados	float64
menciones_tecnologia	Puntuación proxy que cuenta la cantidad de menciones de las 10 tecnologías clave en el texto completo	int64
tipo_contrato	Tipo de convenio laboral	string
jornada	Régimen de horario laboral	string
educacion_minima	Nivel de formación académica más bajo aceptado para el puesto	string
modalidad	Tipo de esquema laboral para el puesto	string

Cuadro 1: Dataset construido a partir de la adquisición de datos.

B. Diccionario de Datos Final

Atributo	Descripción	Tipo
id_oferta	Identificador único de la oferta de trabajo	string
cargo	Categoría del puesto de trabajo según la publicación de la empresa	string
empresa	Nombre de la empresa que postula la oferta	string
ciudad	Ciudad donde se ubica el lugar de trabajo de la oferta	string
salario_publicado	Flag Booleana (0/1) para indicar salario publicado en la oferta.	int64
salario_mensual_base	Remuneración base expresada en Soles (S/.) de forma mensua	float64
segmento_salarial	Categoría de salario (bajo, medio, alto) ofrecido por la oferta	string
experiencia_requerida	Años mínimos de experiencia laboral solicitados	int64
nivel_experiencia	Nivel de Seniority requerido para el candidato	string
educacion_minima	Nivel de formación académica más bajo aceptado para el puesto	string
educacion_minima_valor	Valor ordinal asignado al nivel de educación mínimo requerido por la oferta	int64
modalidad	Tipo de esquema laboral para el puesto	string
es_remoto	Flag booleana (0/1) para indicar ofertas de trabajo remoto	int64
es_presencial	Flag booleana (0/1) para indicar ofertas de trabajo presencial	int64
tipo_contrato	Tipo de convenio laboral	string
jornada	Régimen de horario laboral	string
tiempo_parcial	Flag booleana (0/1) para indicar trabajos a tiempo parcial	int64
menciones_tecnologia	Puntuación proxy que cuenta la cantidad de menciones de las 10 tecnologías clave en el texto completo	int64

Cuadro 2: Dataset resultante de la fase de preprocesamiento.