

Proyecto - Adquisición de Datos

- Saul Baltazar
- Jean Luka Terrazo
- Jose Wong

Este notebook contiene el script utilizado para la fase de adquisición de datos para el desarrollo del proyecto.

Se utilizó la página de [Computrabajo Perú](#), fijando la búsqueda en cargo= Analista y lugar= Lima .

Esta búsqueda arrojó 4226 ofertas de trabajo almacenados en 212 páginas, los cuales se encuentran en 3 archivos csv. La razón para dividir el dataset en 3 partes es para principalmente optimizar el tiempo de scrapeo, puesto que el script permite empezar desde una página determinada. Esto contribuyó a que cada integrante del grupo pueda scrapear un tercio de las ofertas, evitando posibles fallas respecto al tiempo de ejecución del notebook.

Como la cantidad de ofertas cambia dependiendo del momento de ejecución, se decidió que la parte 3 del dataset consistiría únicamente desde donde termina la parte 2 hasta la página 200.

```
In [1]: import requests
from bs4 import BeautifulSoup
from urllib.parse import urljoin
import pandas as pd
import time
import re
```

```
In [ ]: DOMINIO = "https://pe.computrabajo.com"
BASE_URL = f"{DOMINIO}/trabajo-de-analista-en-lima"

HEADERS = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/120.0.0.0 Safari/537.36"
}
```

```
In [ ]: def extraer_datos_nivel_1(bloque_oferta, dominio_base):
    """ Extrae Puesto, URL y Ubicación del bloque de lista, asegurando la URL. """
    datos_oferta = {
        'url_detalle': None,
        'cargo_especifico': None,
        'empresa_nombre': None,
        'ubicacion_provincia': None
    }

    try:
        # Puesto y URL
        titulo_h2 = bloque_oferta.find('h2', class_='fs18 fwB prB')
        if titulo_h2:
            link_tag = titulo_h2.find('a')
            if link_tag:
                href = link_tag.get('href')
                datos_oferta['url_detalle'] = urljoin(dominio_base, href.split('#')[0])
                datos_oferta['cargo_especifico'] = link_tag.get_text(strip=True)

        # Empresa
        empresa_tag = bloque_oferta.find('p', class_='dFlex vm_fx fs16 fc_base mt5')
        if empresa_tag:
            datos_oferta['empresa_nombre'] = empresa_tag.get_text(strip=True)

        # Ubicación
        location_tag = bloque_oferta.find('p', class_='fs16 fc_base mt5')
        if location_tag:
            location_span = location_tag.find('span', class_='mr10')
            if location_span:
                datos_oferta['ubicacion_provincia'] = location_span.get_text(strip=True)

    except Exception as e:
        print(f"Error Nivel I: {e}")

    return datos_oferta
```

```
In [ ]: def extraer_datos_nivel_2(html_content):
    """ Extrae Salario, Experiencia, Contrato, Jornada, Menciones Tech, Educación Mínima y MODALIDAD,
    buscando directamente los tags de detalle. """

    oferta_detalle = {
        'salario_mensual_base': None,
        'experiencia_requerida': None,
        'menciones_tecnologia': 0,
        'tipo_contrato': None,
        'jornada': None,
        'educacion_minima': None,
        'modalidad': 'Presencial' # Valor por defecto
    }

    try:
        SOUP_DETAIL = BeautifulSoup(html_content, 'html.parser')
        full_text = SOUP_DETAIL.get_text().lower()

        tags = SOUP_DETAIL.find_all('span', class_='tag base mb10')
```

```

for tag in tags:
    tag_text = tag.get_text(strip=True)
    tag_text_lower = tag_text.lower()

    # A. Salario (Numérico) o "A convenir"
    salario_match = re.search(r'S\/\.\s*([\d\.,]+)', tag_text)
    if salario_match:
        valor_str = salario_match.group(1).replace('.', '').replace(',', '.')
        oferta_detalle['salario_mensual_base'] = float(valor_str)
        continue

    # B. Jornada (Tiempo completo/parcial)
    if 'tiempo' in tag_text_lower:
        if 'completo' in tag_text_lower:
            oferta_detalle['jornada'] = 'Completa'
        elif 'parcial' in tag_text_lower:
            oferta_detalle['jornada'] = 'Parcial'
        continue

    # C. Modalidad (Presencial/Remoto/Híbrido)
    if 'presencial y remoto' in tag_text_lower:
        oferta_detalle['modalidad'] = 'Híbrido'
        continue
    elif 'remoto' in tag_text_lower:
        oferta_detalle['modalidad'] = 'Remoto'
        continue

    # D. Tipo de Contrato (Si no es salario, jornada, modalidad o "A convenir")
    if tag_text_lower != 'a convenir':
        oferta_detalle['tipo_contrato'] = tag_text
        continue

# Educación Mínima
edu_tag_li = SOUP_DETAIL.find('li', string=lambda t: t and 'educación mínima' in t.lower())
if edu_tag_li:
    edu_text = edu_tag_li.get_text().lower()
    edu_match = re.search(r'educación mínima:\s*([a-záéíóú\s]+)', edu_text)
    if edu_match:
        oferta_detalle['educacion_minima'] = edu_match.group(1).strip()

# Experiencia Requerida (Prioridad: Estructurada)
ul_requerimientos = SOUP_DETAIL.find('p', class_='fwB fs18 mtB mb10', string=lambda t: t and 'requerimientos' in t.lower())
if ul_requerimientos:
    ul_tag = ul_requerimientos.find_next_sibling('ul', class_='disc mbB')
    if ul_tag:
        requerimientos_text = ul_tag.get_text().lower()
        exp_match_req = re.search(r'(\d+)\s+año[s]? \s+de\s+experiencia', requerimientos_text)
        if exp_match_req:
            oferta_detalle['experiencia_requerida'] = int(exp_match_req.group(1))

# Menciones Tecnológicas
tecnologias = ['python', 'sql', 'excel', 'power bi', 'tableau', 'big data', 'ia', 'machine learning', 'sas', 'r']
for tech in tecnologias:
    if tech in full_text:
        oferta_detalle['menciones_tecnologia'] += 1

except Exception as e:
    print(f"Error Nivel II: {e}")

return oferta_detalle

```

```

In [ ]: def ejecutar_scrapeo_por_rango(pagina_inicio, pagina_fin, nombre_archivo_salida):
    """
    Ejecuta el pipeline de scraping en el rango de páginas especificado.
    """
    LISTA_DATOS_FINAL = []
    conteo_registros = 0
    total_paginas = pagina_fin - pagina_inicio + 1

    print("-" * 50)
    print(f"--- INICIANDO SCRAPING: RANGO DE PÁGINAS {pagina_inicio} A {pagina_fin} ---")
    print(f"Total de páginas a procesar: {total_paginas}")

    for i in range(pagina_inicio, pagina_fin + 1):
        URL_PAGINA = f"{BASE_URL}?p={i}"

        try:
            print(f"\nProcesando página {i}/{pagina_fin}: {URL_PAGINA}")

            # 1. SOLICITUD Nivel I (Página de resultados)
            response_n1 = requests.get(URL_PAGINA, headers=HEADERS)
            response_n1.raise_for_status()
            SOUP_N1 = BeautifulSoup(response_n1.content, 'html.parser')

            BLOQUES_OFERTAS = SOUP_N1.find_all('article', class_='box_offer')

            if not BLOQUES_OFERTAS:
                print(f"Página {i} vacía. Fin de los resultados de la búsqueda.")
                break

            # 2. BUCLE: Iterar sobre cada bloque de oferta
            for index, bloque in enumerate(BLOQUES_OFERTAS, 1):
                registro_final = {}

                datos_n1 = extraer_datos_nivel_1(bloque, DOMINIO)
                registro_final.update(datos_n1)

```

```

url_de_detalle = datos_n1['url_detalle']

if url_de_detalle:
    # B. Extracción Nivel II (Detalle)
    try:
        response_n2 = requests.get(url_de_detalle, headers=HEADERS, timeout=10)
        response_n2.raise_for_status()

        datos_n2 = extraer_datos_nivel_2(response_n2.content)
        registro_final.update(datos_n2)

        LISTA_DATOS_FINAL.append(registro_final)
        conteo_registros += 1

    except requests.exceptions.RequestException as e:
        print(f"Error Nivel II en oferta {index}: {e}")

    time.sleep(2)

print(f"Página {i} procesada. Registros extraídos hasta ahora: {conteo_registros}")
time.sleep(10)

except requests.exceptions.RequestException as e:
    print(f"Error de conexión en página {i}: {e}. Esperando 30s y saltando a la siguiente página...")
    time.sleep(30)
    continue
except Exception as e:
    print(f"Error inesperado en página {i}: {e}. Saltando a la siguiente página...")
    time.sleep(10)
    continue

# --- EXPORTACIÓN FINAL ---
df_final = pd.DataFrame(LISTA_DATOS_FINAL)

print("-" * 50)
print(f"Proceso completado. Total de registros válidos extraídos: {len(df_final)}")
df_final.to_csv(nombre_archivo_salida, index=False, encoding='utf-8')
print(f"Archivo '{nombre_archivo_salida}' exportado con éxito.")
print("-" * 50)

```

```

In [ ]: """
Tenemos 4226 ofertas de trabajo de analista en Lima. 20 ofertas por página -> 212 páginas
Tenemos una pausa de 2 segundos entre cada oferta, más una pausa de 10 segundos por página.

En total, si uno solo ejecuta el script, tendría un tiempo de ~ 3 horas.
Mas viable que dividamos la carga de trabajo en 3 scripts con una hora de ejecución por cada uno.
Unir los scripts sería data integration? Si es así, entregamos los scripts por separado.

En resumen, así queda las ejecuciones:
a) 1 - 71
b) 72 - 142
c) 143 - 212
"""

PAGINA_INICIO_GRUPO = 72
PAGINA_FIN_GRUPO = 142
NOMBRE_ARCHIVO_GRUPO = "dataset_analista_lima_parte_2.csv"

ejecutar_scrapeo_por_rango(PAGINA_INICIO_GRUPO, PAGINA_FIN_GRUPO, NOMBRE_ARCHIVO_GRUPO)

```

--- INICIANDO SCRAPING: RANGO DE PÁGINAS 72 A 142 ---
Total de páginas a procesar: 71

Procesando página 72/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=72>
Página 72 procesada. Registros extraídos hasta ahora: 20

Procesando página 73/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=73>
Página 73 procesada. Registros extraídos hasta ahora: 40

Procesando página 74/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=74>
Página 74 procesada. Registros extraídos hasta ahora: 60

Procesando página 75/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=75>
Página 75 procesada. Registros extraídos hasta ahora: 80

Procesando página 76/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=76>
Página 76 procesada. Registros extraídos hasta ahora: 100

Procesando página 77/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=77>
Página 77 procesada. Registros extraídos hasta ahora: 120

Procesando página 78/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=78>
Página 78 procesada. Registros extraídos hasta ahora: 140

Procesando página 79/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=79>
Página 79 procesada. Registros extraídos hasta ahora: 160

Procesando página 80/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=80>
Página 80 procesada. Registros extraídos hasta ahora: 180

Procesando página 81/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=81>
Página 81 procesada. Registros extraídos hasta ahora: 200

Procesando página 82/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=82>
Página 82 procesada. Registros extraídos hasta ahora: 220

Procesando página 83/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=83>
Página 83 procesada. Registros extraídos hasta ahora: 240

Procesando página 84/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=84>
Página 84 procesada. Registros extraídos hasta ahora: 260

Procesando página 85/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=85>
Página 85 procesada. Registros extraídos hasta ahora: 280

Procesando página 86/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=86>
Página 86 procesada. Registros extraídos hasta ahora: 300

Procesando página 87/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=87>
Página 87 procesada. Registros extraídos hasta ahora: 320

Procesando página 88/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=88>
Página 88 procesada. Registros extraídos hasta ahora: 340

Procesando página 89/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=89>
Página 89 procesada. Registros extraídos hasta ahora: 360

Procesando página 90/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=90>
Página 90 procesada. Registros extraídos hasta ahora: 380

Procesando página 91/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=91>
Página 91 procesada. Registros extraídos hasta ahora: 400

Procesando página 92/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=92>
Página 92 procesada. Registros extraídos hasta ahora: 420

Procesando página 93/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=93>
Página 93 procesada. Registros extraídos hasta ahora: 440

Procesando página 94/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=94>
Página 94 procesada. Registros extraídos hasta ahora: 460

Procesando página 95/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=95>
Página 95 procesada. Registros extraídos hasta ahora: 480

Procesando página 96/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=96>
Página 96 procesada. Registros extraídos hasta ahora: 500

Procesando página 97/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=97>
Página 97 procesada. Registros extraídos hasta ahora: 520

Procesando página 98/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=98>
Página 98 procesada. Registros extraídos hasta ahora: 540

Procesando página 99/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=99>
Página 99 procesada. Registros extraídos hasta ahora: 560

Procesando página 100/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=100>
Página 100 procesada. Registros extraídos hasta ahora: 580

Procesando página 101/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=101>
Página 101 procesada. Registros extraídos hasta ahora: 600

Procesando página 102/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=102>
Página 102 procesada. Registros extraídos hasta ahora: 620

Procesando página 134/142: <https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=134>
Página 134 procesada. Registros extraídos hasta ahora: 1369

Procesando página 135/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=135
Página 135 procesada. Registros extraídos hasta ahora: 1280

Procesando página 136/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=136
Página 136 procesada. Registros extraídos hasta ahora: 1300

Procesando página 137/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=137
Página 137 procesada. Registros extraídos hasta ahora: 1320

Procesando página 138/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=138
Página 138 procesada. Registros extraídos hasta ahora: 1340

Procesando página 139/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=139
Página 139 procesada. Registros extraídos hasta ahora: 1360

Procesando página 140/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=140
Página 140 procesada. Registros extraídos hasta ahora: 1380

Procesando página 141/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=141
Página 141 procesada. Registros extraídos hasta ahora: 1400

Procesando página 142/142: https://pe.computrabajo.com/trabajo-de-analista-en-lima?p=142
Página 142 procesada. Registros extraídos hasta ahora: 1420

Proceso completado. Total de registros válidos extraídos: 1420
Archivo 'dataset_analista_lima_parte_2.csv' exportado con éxito.

In []:

```
# De La prueba

df_display
```


Out[]:

	cargo_especifico	ubicacion_provincia	modalidad	salario_mensual_base	experiencia_requerida	educacion_minima	tipo_contrato	jornada	menciones_tecnologias
0	Analista GTR Ventas Portabilidad	Lima, Lima	Presencial	NaN	1.0	técnico	Contrato por Inicio o Incremento de Actividad	Completa	!
1	Analista Contable	Santa Anita, Lima	Presencial	2000.0	2.0	universitario	Contrato por Obra Determinada o Servicio Espec...	Completa	4
2	Analista de Almacén MP / Temporal (Suplencia ...	Ate, Lima	Presencial	NaN	2.0	universitario	Contrato de Suplencia	Completa	4
3	Analista de Control de Calidad	Ate, Lima	Presencial	NaN	3.0	universitario	Contrato por Obra Determinada o Servicio Espec...	Completa	4
4	Analista contable	San Luis, Lima	Presencial	2700.0	2.0	universitario	Contrato por Obra Determinada o Servicio Espec...	Completa	4
5	Analista de propuestas	Magdalena Del Mar, Lima	Presencial	NaN	2.0	universitario	Contrato por Inicio o Incremento de Actividad	Completa	:
6	Analista Programador de Sistemas .NET Presenci...	Pisco, Ica	Presencial	NaN	2.0	técnico	Contrato por Obra Determinada o Servicio Espec...	Completa	4
7	Analista de Créditos y Cobranzas	Villa Maria Del Triunfo, Lima	Presencial	NaN	2.0	técnico	Contrato por Necesidades del Mercado	Completa	4
8	Analista de Gestión del Talento	Santiago De Surco, Lima	Híbrido	NaN	NaN	técnico	Contrato por Inicio o Incremento de Actividad	Completa	4
9	analista de calidad	Lima, Lima	Híbrido	NaN	1.0	universitario	Contrato por Obra Determinada o Servicio Espec...	Completa	4
10	Analista de Producción TI	Ate, Lima	Presencial	NaN	2.0	universitario	Contrato por Inicio o Incremento de Actividad	Completa	!
11	Analista Jr. de Recojo y Embarque / Distribuci...	Breña, Lima	Presencial	NaN	2.0	técnico	Contrato por Inicio o Incremento de Actividad	Completa	4
12	Analista en Licitaciones o Contrataciones del ...	Carabayllo, Lima	Presencial	3000.0	3.0	universitario	Contrato por Necesidades del Mercado	Completa	4
13	Analista QA con experiencia en datos	San Isidro, Lima	Híbrido	4900.0	NaN	técnico	Contrato por Inicio o Incremento de Actividad	Completa	6
14	Analista de marketing digital	Lima, Lima	Remoto	NaN	2.0	universitario	Contrato por Inicio o Incremento de Actividad	Completa	4
15	Analista de Clima y Cultura	Pacasmayo, La Libertad	Presencial	NaN	2.0	universitario	Contrato por Inicio o Incremento de Actividad	Completa	!
16	Analista BI	Miraflores, Lima	Híbrido	NaN	2.0	técnico	Contrato por Inicio o Incremento de Actividad	Completa	6
17	Analista de Control de Inventarios	Lima, Lima	Presencial	NaN	2.0	universitario	Contrato por Inicio o Incremento de Actividad	Completa	!

